

Data Understanding — Tabla RRHH_07072026

Equipo 33 - 06/06/2026

Volumen datos

Indicador	Valor
Total de registros	740
Columnas (atributos)	21
ID únicos (empleados)	36
Registros por empleado	704
Combinaciones duplicadas	26
Filas sobrantes por duplicado	34

Revisión por campo

Campo	Tipo	Unidad	Problema detectado	Recomendación
id_registro*	—	-	No existe un identificador único de registro	Crear ID_absencia como clave primaria
ID	int	-	Identifica al empleado, no al registro	Renombrar a ID_empleado
Reason_absence	int	-	Códigos del 0 al 28 (falta el 20)	Ver diccionario código
Month_absence	int	-	3 registros con valor 0 (mes no válido)	Revisar esos 3 registros
Day_week	int	-	Solo aparecen valores del 2 al 6	2=Lunes ... 6=Viernes
Seasons	int	-	Valores del 1 al 4	Info original omitida. Se asignan las estaciones según el calendario español
Transportation_expense	int	EUR	Sin incidencias. Unidad acordada.	—
Distance_Residence_Work	int	Km	Sin incidencias.	
Service_time	int	Años	Rango correcto (Antigüedad del empleado). Unidad asumida	
Age	int	Años	Rango correcto. Unidad asumida	—
Work_load_Average_day	varchar(512)	Índice	Debería ser numérico; usa coma decimal.	Convertir a float y , por .
Hit_target	int	-	Rango de 81 a 100.	Convertir a booleano
Disciplinary_failure	varchar(512)	-	Es un valor binario (1=sí, 0=no)	
Education	varchar(512)	-	Códigos del 1 al 4	

Data Understanding — Tabla RRHH_07072026

Campo	Tipo	Unidad	Problema detectado	Recomendación
Son	varchar(512)	-	Número de hijos, guardado como texto	Convertir a tipo entero
Social_drinker	varchar(512)	-	Es un valor binario (1=sí, 0=no)	Convertir a booleano
Social_smoker	varchar(512)	-	Es un valor binario (1=sí, 0=no)	Convertir a booleano
Pet	varchar(512)	-	Número de mascotas, guardado como texto	Convertir a tipo entero
Weight	int	Kg	Unidad asumida por rango.	—
Height	int	Cm	Unidad asumida por rango.	—
Body_mass_index	int	-	Rango correcto, coincide con el cálculo real	—
Absenteeism_hours	int	horas	Rango de 0 a 120 horas	Variable objetivo

Resumen:

Misma que la semana anterior. No hay valores nulos y los rangos numéricos son coherentes, pero hay varios problemas de estructura y de tipo de dato por resolver.

Próximos pasos (Data Cleaning):

- Crear ID_absencia como clave primaria y renombrar ID a ID_empleado
- Eliminar las 34 filas duplicadas, dejando un solo registro por combinación
- Convertir las columnas con tipo incorrecto: booleano, entero o numérico según el caso
- Aplicar el diccionario de Reason_absence, Day_week y Education ya confirmado
- Mantener los 3 registros de Month_absence = 0
- Se cambiarán

Data Understanding — Tabla RRHH_07072026

Anexo: Diccionario de códigos

Day_week

Código	Día
2	Lunes
3	Martes
4	Miércoles
5	Jueves
6	Viernes

Education

Código	Nivel
1	Educación secundaria
2	Graduado
3	Postgrado
4	Máster o doctorado

Seasons

Código	Nivel
1	Invierno
2	Primavera
3	Verano
4	Otoño

Reason_absence

Código	Significado
1	Enfermedades infecciosas y parasitarias
2	Neoplasias (tumores)
3	Enfermedades de la sangre y del sistema inmunitario
4	Enfermedades endocrinas, nutricionales y metabólicas
5	Trastornos mentales y del comportamiento
6	Enfermedades del sistema nervioso

Data Understanding — Tabla RRHH_07072026

Código	Significado
7	Enfermedades del ojo
8	Enfermedades del oído
9	Enfermedades del sistema circulatorio
10	Enfermedades del sistema respiratorio
11	Enfermedades del sistema digestivo
12	Enfermedades de la piel
13	Enfermedades del sistema musculoesquelético
14	Enfermedades del sistema genito-urinario
15	Embarazo, parto y puerperio
16	Afecciones del periodo perinatal
17	Malformaciones congénitas
18	Síntomas y hallazgos clínicos no clasificados
19	Lesiones y envenenamientos
20	Causas externas de morbilidad (sin registros en la tabla)
21	Factores que influyen en el estado de salud
22	Seguimiento de paciente
23	Consulta médica
24	Donación de sangre
25	Examen de laboratorio
26	Ausencia injustificada
27	Fisioterapia
28	Consulta dental